

Projet CNN - Classification de lésions cutanées

Robin Bouvier Leho Pendanx

ENSEIRB-MATMECA

Avril 2026

1. Présentation du dataset

Exemples d'images du dataset Melanoma




Figure – Échantillons de lésions : distinction subtile.

1bis. Distribution des classes




Figure – Répartition des images dans le dataset

Commentaire

La répartition des deux classes est quasi-équitable. Cela permet d'éviter qu'un biais naturel ne favorise l'apprentissage d'une classe au détriment de l'autre.

2. Représentation des données

Que signifie $[3, 224, 224]$?

- 3 : Canaux RGB (Rouge, Vert, Bleu).
- 224x224 : Résolution spatiale.

Pourquoi valeurs entre 0 et 1 ?

- Normalisation via `ToTensor()`.
- Stabilise les gradients.



Figure – Visualisation des canaux couleur

3. Dataset et DataLoader (Concepts)

Structure du code

Dataset : Le réservoir (accès indexé).

DataLoader : Le robinet (gestion des batchs et shuffle).

Notions clés :

- **Batch** : Groupe d'images (512 dans nos entraînements) traitées en parallèle.
- **Shuffle** : Mélange indispensable pour éviter la mémorisation de l'ordre.

3bis. Dataset et DataLoader (Visualisation)




Figure – Visualisation des batchs Train et Val

Commentaire technique

Le **Batch** permet de paralléliser le calcul sur GPU tout en gardant une estimation stable du gradient.

4. Comprendre l'apprentissage

Le moteur de calcul

- **Loss (Erreur)** : Mesure l'écart entre prédiction et réalité.
- **Formule CrossEntropy** : $L = - \sum y_i \log(\hat{y}_i)$.
- **Gradient** : Direction de mise à jour des poids.
- **Learning Rate** : Taille du pas effectué à chaque mise à jour des poids.

Métriques de suivi

- **Epoch** : Un passage complet sur le dataset.
- **Accuracy** : Pourcentage de prédictions correctes.

5. Premier CNN : Architecture et Limites

Architecture "from scratch"

- Convolutions (filtres locaux).
- ReLU (non-linéarité).
- Pooling (réduction).

Statistiques Modèle

Total : 4 218 658 paramètres

Observations

Pas de surapprentissage
(overfitting) majeur.
Prédictions très instables.




Figure – Courbes d'apprentissage initiales

6. Normalisation : Principe

Principe

- Centrage sur 0 et réduction.
- Évite qu'une plage de couleurs ne domine l'apprentissage.

Effet de la normalisation sur une image

Avant Normalisation
Min: 0.07, Max: 0.95



Après Normalisation
Min: -2.49, Max: 1.19




Figure – Comparaison avant/après normalisation

6bis. Normalisation : Impact




Figure – Gain de convergence observé

Commentaire

Surapprentissage (overfitting) net.

Écart de généralisation : le modèle apprend le set d'entraînement par cœur (s'approchant des 100)

7. Data augmentation : Stratégie visuelle




Figure – Génération de 8 versions augmentées

Objectif

Multiplier artificiellement les images pour forcer le réseau à apprendre des caractéristiques robustes.

7bis. Impact de la Data Augmentation





Figure – Comparaison des courbes avec/sans augmentation

Analyse

La réduction de l'écart Accuracy Train / Accuracy Val confirme une meilleure généralisation du modèle.

8. Choix de l'optimiseur et du LR

Configurations testées

- Adam vs SGD.
- Adam : Learning Rate adaptatif.
- Résilience aux surfaces de coût complexes.




Figure – Comparaison des optimiseurs

9. Scheduler : Optimisation du LR




Figure – Évolution du Learning Rate par paliers

Observation

Le scheduler diminue trop vite le LR, e qui entraîne la stagnation du modèle.

10. Suivi TensorBoard : Loss




Figure – Comparaison des courbes de Loss via TensorBoard

Commentaire

TensorBoard permet de superposer les différents runs afin d'identifier la meilleure configuration en temps réel pendant l'entraînement.

11. ResNet18 et Transfer Learning

Statistiques Modèle

Total : 11,177,538
Entraînables : 1,026
Gelés : 11,176,512

Méthode

- Poids pré-entraînés ImageNet.
- Extraction de *features* figée.




Figure – Transfer Learning (backbone gelé)

Comparaison : CNN Maison vs ResNet18 (Tête seule)

- CNN Maison (Basic) : $\approx 94\%$ d'accuracy en validation.
- ResNet18 (Backbone gelé) : $\approx 85\%$ d'accuracy en validation.

Analyse : Cela s'explique car les **features** extraites par le ResNet sont très générales.

12. Fine-tuning : Dégel progressif

Configuration des paramètres

Cas 1 (C4 dégelé) : 1,026,434 entraînaibles / 10,151,104 gelés

Cas 2 (C3+C4 dégelés) : 8,394,754 entraînaibles / 2,782,784 gelés




Figure – Impact du dégel des couches convolutionnelles

Analyse des performances

Dans ces deux configurations, le modèle atteint une **accuracy de validation supérieure à 98 %**.

12bis. Bilan : Comparaison des Modèles

Métrique	CNN Maison	ResNet18 (Gelé)	ResNet18 (Fine-tuné C4)
Paramètres entraînables	4 218 658	1 026	1 026 434
Accuracy (Validation)	94 %	85 %	98 %

13. Évaluation : Matrice de Confusion

Analyse des prédictions

- **Faux Négatifs (103) :**
Cas critiques (mélanome non détecté).
- **Faux Positifs (93) :**
Fausses alertes.
- Classification globalement très robuste.




Figure – Matrice de confusion du ResNet18

13bis. Exemples de succès

□ Succès : 4 Vrais Bénins (haut) et 4 Vrais Malins (bas)




Figure – Prédictions correctes

13ter. Analyse des limites : Les erreurs

⚠ Erreurs : 4 Faux Positifs (haut) et 4 Faux Négatifs (bas)




Figure – Cas d'échec

Modèle retenu : ResNet18 (Fine-tuné sur C4)

- **Meilleur compromis** : 98 % d'accuracy pour seulement ~ 1 million de paramètres entraînés.
- **Clés du succès** : Transfer Learning + Data Augmentation.

Perspectives

- **Interprétabilité** : Utiliser Grad-CAM pour visualiser les zones détectées par l'IA (crucial en médical).
- **Gestion des classes** : Appliquer une *Weighted Loss* pour mieux cibler les erreurs rares.
- **Architectures** : Tester des modèles plus complexes comme ResNet50.